

Apostila Didática de Ajustes, Aproximações e Interpolação

Baseada no PDF *Análise Numérica & Cálculo Numérico — Regressão Linear, MMQ e Interpolação*

Material reorganizado e expandido em formato de apostila

28 de abril de 2026

Sumário

1	Introdução	4
2	Interpolação versus aproximação	4
2.1	Ideia intuitiva	4
2.2	Visualização conceitual	5
3	Método dos Mínimos Quadrados (MMQ)	5
3.1	Motivação intuitiva	5
3.2	Por que o quadrado do erro?	6
3.3	Regressão linear	6
3.3.1	Passo intuitivo	6
3.3.2	Definição formal	6
3.3.3	Derivação passo a passo	7
3.4	Exemplo resolvido de regressão linear	8
3.5	Visualização do ajuste e dos resíduos	9
3.6	Erros comuns	9
4	Estatística do ajuste e análise de erros	9
4.1	Análise de resíduos	9
4.2	Erro padrão da estimativa	10

4.3	Coeficiente de determinação r^2	10
4.4	Coeficiente de correlação r	11
5	Linearização de funções não lineares	11
5.1	Ideia geral	11
5.2	Modelo exponencial	11
5.3	Modelo de potência	11
5.4	Modelo de saturação	12
6	Aproximação polinomial de grau arbitrário	13
6.1	Caso discreto	13
6.1.1	Derivação das equações normais	13
6.2	Caso contínuo	14
7	Interpolação polinomial	15
7.1	Ideia intuitiva	15
8	Fórmula de Lagrange	15
8.1	Construção intuitiva	15
8.2	Exemplo resolvido	16
8.3	Erro comum	16
9	Diferenças divididas de Newton	17
9.1	Por que usar Newton?	17
9.2	Definição formal	17
9.3	Exemplo resolvido	17
9.4	Tabela triangular de diferenças divididas	18
10	Interpolação por splines	18
10.1	Motivação	18
10.2	Splines lineares, quadráticas e cúbicas	18

10.3 Forma da spline cúbica natural	19
10.4 Esquema conceitual	19
11 Implementação detalhada em Python	19
11.1 Resolvendo sistemas lineares: eliminação de Gauss	20
11.2 Implementando regressão linear por MMQ	22
11.3 Cálculo de resíduos, r^2 e erro padrão	23
11.4 Ajuste polinomial de grau arbitrário	24
11.5 Interpolação de Lagrange	25
11.6 Diferenças divididas de Newton	25
11.7 Spline cúbica natural	26
12 Quando usar cada método?	28
13 Conclusão	28

1 Introdução

Quando temos uma tabela de dados experimentais, geralmente queremos responder a uma pergunta central: *qual função descreve esses dados?* Em análise numérica, essa pergunta aparece em contextos muito diferentes: medições físicas, crescimento populacional, calibração de sensores, curvas de custo, fenômenos biológicos e muitas outras situações.

O PDF fornecido aborda exatamente esse problema por duas grandes estratégias:

- **aproximação:** aceitar pequenos erros para obter um modelo simples e útil;
- **interpolação:** exigir que a função passe exatamente por todos os pontos dados.

Nesta apostila, o conteúdo foi reorganizado com progressão didática do simples para o mais sofisticado. A ideia é não apenas apresentar fórmulas, mas explicar **por que elas aparecem, como usá-las e como implementá-las em Python sem recorrer a bibliotecas que façam o trabalho automaticamente**. Sempre que possível, destacaremos a interpretação geométrica e os erros mais comuns.

Definição

Objetivo geral. Dado um conjunto de pontos (x_i, y_i) , queremos construir uma função que permita:

- representar o comportamento dos dados;
- estimar valores intermediários;
- resumir tendências;
- quantificar a qualidade do ajuste.

Observação

Ao longo da apostila, distinguiremos duas perguntas diferentes:

1. *Quero uma função que passe exatamente pelos pontos?*
2. *Quero uma função que represente bem a tendência geral, mesmo errando um pouco?*

A primeira leva à **interpolação**; a segunda leva à **aproximação por mínimos quadrados**.

2 Interpolação versus aproximação

2.1 Ideia intuitiva

Suponha que você mediu a temperatura de um processo em alguns instantes. Se confiar completamente nos dados, pode exigir uma curva que passe por todos os pontos. Isso é interpolar. Mas se suspeitar que há ruído experimental, talvez seja melhor ajustar uma curva que não passe exatamente por todos eles, mas capture a tendência principal. Isso é aproximar.


Definição

Interpolação é o processo de construir uma função $P(x)$ tal que

$$P(x_i) = y_i \quad \text{para todo } i.$$

Aproximação é o processo de construir uma função $f(x)$ que não necessariamente satisfaça $f(x_i) = y_i$, mas torne os erros “pequenos” de acordo com algum critério.

2.2 Visualização conceitual

**Observação**

A interpolação é excelente quando os dados são considerados exatos ou quando precisamos reproduzir rigorosamente valores tabelados. Já a aproximação é mais adequada quando os dados contêm ruído de medição.

3 Método dos Mínimos Quadrados (MMQ)

3.1 Motivação intuitiva

Considere uma nuvem de pontos que parece seguir aproximadamente uma reta. Queremos escolher a “melhor” reta. Mas o que significa “melhor”?

Uma primeira ideia seria minimizar a soma dos resíduos $e_i = y_i - \hat{y}_i$. O problema é que erros positivos e negativos podem se cancelar. Outra ideia seria minimizar a soma dos módulos $|e_i|$, mas isso gera dificuldades analíticas e, em certos cenários, não fornece uma solução tão conveniente. O método mais usado consiste em minimizar a soma dos **quadrados** dos resíduos.

Definição

Dado um modelo $\hat{y}_i = f(x_i)$, chamamos de **resíduo** o valor

$$e_i = y_i - \hat{y}_i.$$

No método dos mínimos quadrados, escolhemos os parâmetros do modelo de modo a minimizar

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - f(x_i))^2.$$

Fórmula em destaque

$$\text{MMQ: minimizar } S_r = \sum_{i=1}^n (y_i - f(x_i))^2$$

3.2 Por que o quadrado do erro?

Há três motivos principais:

1. resíduos positivos e negativos não se cancelam;
2. erros maiores recebem penalização mais forte;
3. o problema leva a equações normais que podem ser resolvidas de forma sistemática.

3.3 Regressão linear

Agora vamos assumir que o modelo procurado é uma reta:

$$\hat{y} = a_0 + a_1 x.$$

3.3.1 Passo intuitivo

Cada ponto (x_i, y_i) fica a uma distância vertical da reta. Queremos escolher a_0 e a_1 para que, no total, essas distâncias ao quadrado sejam as menores possíveis.

3.3.2 Definição formal

Para os dados $(x_1, y_1), \dots, (x_n, y_n)$, definimos

$$S_r(a_0, a_1) = \sum_{i=1}^n [y_i - (a_0 + a_1 x_i)]^2.$$

Precisamos encontrar o ponto (a_0, a_1) que minimiza essa função.

3.3.3 Derivação passo a passo

Como S_r depende de a_0 e a_1 , derivamos parcialmente:

$$\frac{\partial S_r}{\partial a_0} = 0, \quad \frac{\partial S_r}{\partial a_1} = 0.$$

Expandindo:

$$\frac{\partial}{\partial a_0} \sum_{i=1}^n [y_i - (a_0 + a_1 x_i)]^2 = 0.$$

Pela regra da cadeia,

$$-2 \sum_{i=1}^n [y_i - a_0 - a_1 x_i] = 0.$$

Dividindo por -2 ,

$$\sum_{i=1}^n y_i - n a_0 - a_1 \sum_{i=1}^n x_i = 0.$$

Logo,

$$n a_0 + a_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i.$$

Fazendo o mesmo para a_1 :

$$\frac{\partial}{\partial a_1} \sum_{i=1}^n [y_i - (a_0 + a_1 x_i)]^2 = 0$$

leva a

$$\sum_{i=1}^n x_i y_i - a_0 \sum_{i=1}^n x_i - a_1 \sum_{i=1}^n x_i^2 = 0,$$

ou seja,

$$a_0 \sum_{i=1}^n x_i + a_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i.$$

Fórmula em destaque

As **equações normais** da regressão linear são

$$\begin{cases} n a_0 + a_1 \sum x_i = \sum y_i, \\ a_0 \sum x_i + a_1 \sum x_i^2 = \sum x_i y_i. \end{cases}$$

Resolvendo esse sistema, obtemos a reta de regressão.

3.4 Exemplo resolvido de regressão linear

Considere os pontos

$$(1, 1.2), (2, 1.9), (3, 3.2), (4, 3.9), (5, 5.1).$$

Exemplo resolvido

Vamos ajustar uma reta $\hat{y} = a_0 + a_1x$.

Passo 1: montar a tabela.

x_i	y_i	x_i^2	$x_i y_i$
1	1.2	1	1.2
2	1.9	4	3.8
3	3.2	9	9.6
4	3.9	16	15.6
5	5.1	25	25.5

Passo 2: somatórios.

$$\sum x_i = 15, \quad \sum y_i = 15.3, \quad \sum x_i^2 = 55, \quad \sum x_i y_i = 55.7.$$

Passo 3: equações normais.

$$\begin{cases} 5a_0 + 15a_1 = 15.3, \\ 15a_0 + 55a_1 = 55.7. \end{cases}$$

Passo 4: resolver o sistema. Da primeira equação,

$$a_0 = 3.06 - 3a_1.$$

Substituindo na segunda:

$$15(3.06 - 3a_1) + 55a_1 = 55.7.$$

Então,

$$45.9 - 45a_1 + 55a_1 = 55.7 \Rightarrow 10a_1 = 9.8 \Rightarrow a_1 = 0.98.$$


Logo,

$$a_0 = 3.06 - 2.94 = 0.12.$$

Conclusão. A reta ajustada é

$$\hat{y} = 0.12 + 0.98x.$$

3.5 Visualização do ajuste e dos resíduos



3.6 Erros comuns

Observação

Erros frequentes na regressão linear:

- confundir resíduo com erro absoluto;
- esquecer que a regressão minimiza distâncias *verticais*;
- usar regressão linear quando os dados claramente têm comportamento não linear;
- calcular errado os somatórios, o que compromete todo o resultado.

4 Estatística do ajuste e análise de erros

4.1 Análise de resíduos

Intuição. Depois de ajustar um modelo, não basta olhar a curva. Precisamos observar os resíduos. Se eles forem pequenos e sem padrão aparente, o ajuste tende a ser adequado. Se crescerem, alternarem sistematicamente ou apresentarem curvatura, isso sugere que o modelo escolhido não é o melhor.

Definição

Para cada ponto, o resíduo é

$$e_i = y_i - \hat{y}_i.$$

O conjunto dos resíduos indica como o modelo se distancia dos dados.

No exemplo anterior:

$$\hat{y}_i = 0.12 + 0.98x_i.$$

Assim,

$$\hat{y} = (1.10, 2.08, 3.06, 4.04, 5.02).$$

Logo,

$$e = (0.10, -0.18, 0.14, -0.14, 0.08).$$

4.2 Erro padrão da estimativa

Definição

Na regressão linear, o **erro padrão da estimativa** é

$$S_{y/x} = \sqrt{\frac{S_r}{n-2}},$$

onde

$$S_r = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

O termo $n - 2$ aparece porque dois parâmetros (a_0 e a_1) foram estimados a partir dos dados.

Para o nosso exemplo,

$$S_r = 0.10^2 + (-0.18)^2 + 0.14^2 + (-0.14)^2 + 0.08^2 = 0.088.$$

Então,

$$S_{y/x} = \sqrt{\frac{0.088}{5-2}} \approx 0.1713.$$

4.3 Coeficiente de determinação r^2

Intuição. O valor r^2 mede quanto da variabilidade dos dados é explicada pelo modelo.

Definição

Seja

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad S_t = \sum_{i=1}^n (y_i - \bar{y})^2.$$

Então o coeficiente de determinação é dado por

$$r^2 = \frac{S_t - S_r}{S_t} = 1 - \frac{S_r}{S_t}.$$

Quanto mais próximo de 1, melhor o ajuste linear em relação à média dos dados.

4.4 Coeficiente de correlação r

Definição

O **coeficiente de correlação linear** mede a força e o sentido da relação linear entre x e y . Em regressão linear simples,

$$r = \text{sgn}(a_1)\sqrt{r^2}.$$

Observação

Um valor alto de r não prova causalidade. Ele apenas indica associação linear forte entre as variáveis observadas.

5 Linearização de funções não lineares

5.1 Ideia geral

Nem sempre os dados seguem uma reta. Em muitos casos, porém, um modelo não linear pode ser transformado em um modelo linear por troca de variáveis. Isso permite aplicar o MMQ linear em variáveis transformadas.

5.2 Modelo exponencial

Considere

$$y = ab^x.$$

Tomando logaritmo:

$$\ln y = \ln a + x \ln b.$$

Se definirmos

$$Y = \ln y, \quad A = \ln a, \quad B = \ln b,$$

então

$$Y = A + Bx,$$

que é linear.

5.3 Modelo de potência

Considere

$$y = ax^b.$$

Tomando logaritmo:

$$\ln y = \ln a + b \ln x.$$

Definindo

$$Y = \ln y, \quad X = \ln x,$$

obtemos

$$Y = A + bX, \quad \text{com } A = \ln a.$$

5.4 Modelo de saturação

Um formato típico é

$$y = \frac{ax}{b+x}.$$

Invertendo,

$$\frac{1}{y} = \frac{b+x}{ax} = \frac{b}{a} \frac{1}{x} + \frac{1}{a}.$$

Se definirmos

$$Y = \frac{1}{y}, \quad X = \frac{1}{x},$$

então

$$Y = \frac{b}{a}X + \frac{1}{a},$$

que também é linear.

Exemplo resolvido

Suponha que um fenômeno siga aproximadamente um modelo exponencial e tenhamos os dados

$$(0, 2.0), (1, 2.7), (2, 3.6), (3, 4.9).$$

Passo 1: linearizar. Calculamos $Y_i = \ln y_i$:

$$(0, 0.6931), (1, 0.9933), (2, 1.2809), (3, 1.5892).$$

Passo 2: ajustar a reta $Y = A + Bx$. Depois do MMQ, obtemos aproximadamente

$$A \approx 0.696, \quad B \approx 0.298.$$

Passo 3: voltar à variável original. Como $A = \ln a$ e $B = \ln b$, temos

$$a = e^A \approx 2.006, \quad b = e^B \approx 1.347.$$

Portanto,

$$y \approx 2.006 (1.347)^x.$$

Observação

Ao linearizar, o MMQ minimiza erros na variável transformada, não necessariamente na variável original. Isso deve ser lembrado ao interpretar o ajuste.

6 Aproximação polinomial de grau arbitrário

6.1 Caso discreto

Intuição. Se uma reta é simples demais e uma parábola ainda não é suficiente, podemos procurar um polinômio de grau m :

$$P_m(x) = a_0 + a_1x + a_2x^2 + \cdots + a_mx^m.$$

A ideia continua sendo minimizar a soma dos quadrados dos resíduos.

Definição

No caso discreto, queremos minimizar

$$S_r = \sum_{i=1}^n [y_i - P_m(x_i)]^2.$$

Isso leva a um sistema linear para os coeficientes $a_0, a_1, \dots, a_m$.

6.1.1 Derivação das equações normais

Substituindo o polinômio,

$$S_r = \sum_{i=1}^n \left[y_i - \sum_{k=0}^m a_k x_i^k \right]^2.$$

Derivando em relação a cada a_j e igualando a zero:

$$\frac{\partial S_r}{\partial a_j} = 0, \quad j = 0, 1, \dots, m.$$

Isso gera

$$\sum_{i=1}^n x_i^j \left[y_i - \sum_{k=0}^m a_k x_i^k \right] = 0.$$

Reorganizando,

$$\sum_{k=0}^m a_k \sum_{i=1}^n x_i^{j+k} = \sum_{i=1}^n x_i^j y_i, \quad j = 0, 1, \dots, m.$$

Fórmula em destaque

Para ajuste polinomial discreto de grau m , as equações normais são

$$\sum_{k=0}^m a_k \left(\sum_{i=1}^n x_i^{j+k} \right) = \sum_{i=1}^n x_i^j y_i, \quad j = 0, 1, \dots, m.$$

6.2 Caso contínuo

Quando queremos aproximar uma função contínua $f(x)$ por um polinômio em um intervalo $[\alpha, \beta]$, a soma discreta é substituída por uma integral.

Definição

No caso contínuo, procuramos $P_m(x)$ que minimize

$$\int_{\alpha}^{\beta} (f(x) - P_m(x))^2 dx.$$

As equações normais tornam-se

$$\int_{\alpha}^{\beta} x^j P_m(x) dx = \int_{\alpha}^{\beta} x^j f(x) dx, \quad j = 0, 1, \dots, m.$$

Exemplo resolvido

Queremos ajustar uma parábola aos dados

$$(-1, 2), (0, 1), (1, 2), (2, 5).$$

Tomamos

$$P_2(x) = a_0 + a_1x + a_2x^2.$$

Calculamos os somatórios:

$$\sum x_i = 2, \quad \sum x_i^2 = 6, \quad \sum x_i^3 = 8, \quad \sum x_i^4 = 18,$$

$$\sum y_i = 10, \quad \sum x_i y_i = 10, \quad \sum x_i^2 y_i = 24.$$

As equações normais ficam

$$\begin{cases} 4a_0 + 2a_1 + 6a_2 = 10, \\ 2a_0 + 6a_1 + 8a_2 = 10, \\ 6a_0 + 8a_1 + 18a_2 = 24. \end{cases}$$

Resolvendo o sistema, obtemos

$$a_0 = 1, \quad a_1 = 0, \quad a_2 = 1.$$

Logo,

$$P_2(x) = 1 + x^2.$$

Neste caso, o ajuste reproduziu exatamente os dados.

7 Interpolação polinomial

7.1 Ideia intuitiva

Na interpolação, não aceitamos erro nos nós dados. Se temos $n + 1$ pontos com abscissas distintas, existe um único polinômio de grau no máximo n que passa por todos eles.

Definição

Dados $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$ com $x_i \neq x_j$ para $i \neq j$, o **polinômio interpolador** $P_n(x)$ satisfaz

$$P_n(x_i) = y_i, \quad i = 0, 1, \dots, n.$$

Observação

Embora a interpolação seja exata nos nós, isso não significa que o polinômio seja bom fora deles. Em graus altos, podem surgir oscilações grandes, especialmente perto das extremidades do intervalo.

8 Fórmula de Lagrange

8.1 Construção intuitiva

Queremos combinar blocos básicos que “liguem” um ponto e “desliguem” os outros. Para isso, construímos polinômios $L_k(x)$ com a propriedade:

$$L_k(x_i) = \begin{cases} 1, & i = k, \\ 0, & i \neq k. \end{cases}$$

Assim, cada termo $y_k L_k(x)$ contribui com y_k apenas no nó x_k .

Definição

Os **polinômios fundamentais de Lagrange** são

$$L_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j}.$$

O polinômio interpolador é

$$P_n(x) = \sum_{k=0}^n y_k L_k(x).$$

8.2 Exemplo resolvido

Vamos interpolar os pontos

$$(1, 2), (2, 3), (4, 1).$$

Exemplo resolvido

Como temos três pontos, procuramos um polinômio de grau no máximo 2.

Passo 1: calcular os polinômios básicos.

$$L_0(x) = \frac{(x-2)(x-4)}{(1-2)(1-4)} = \frac{(x-2)(x-4)}{3},$$

$$L_1(x) = \frac{(x-1)(x-4)}{(2-1)(2-4)} = -\frac{(x-1)(x-4)}{2},$$

$$L_2(x) = \frac{(x-1)(x-2)}{(4-1)(4-2)} = \frac{(x-1)(x-2)}{6}.$$

Passo 2: montar $P_2(x)$.

$$P_2(x) = 2L_0(x) + 3L_1(x) + 1L_2(x).$$

Substituindo:

$$P_2(x) = \frac{2}{3}(x-2)(x-4) - \frac{3}{2}(x-1)(x-4) + \frac{1}{6}(x-1)(x-2).$$

Passo 3: simplificar. Após expandir e somar os termos,

$$P_2(x) = -\frac{5}{6}x^2 + \frac{19}{6}x - \frac{1}{3}.$$

Passo 4: conferir.

$$P_2(1) = 2, \quad P_2(2) = 3, \quad P_2(4) = 1.$$

8.3 Erro comum

Observação

Um erro muito comum na fórmula de Lagrange é trocar o denominador $(x_k - x_j)$ por $(x - x_j)$. O denominador deve ser constante em cada bloco L_k .

9 Diferenças divididas de Newton

9.1 Por que usar Newton?

A fórmula de Lagrange é conceitualmente elegante, mas a forma de Newton é mais eficiente quando novos pontos são adicionados. Em vez de reconstruir tudo, basta acrescentar um novo termo.

9.2 Definição formal

Definição

As **diferenças divididas** são definidas recursivamente por

$$\begin{aligned}f[x_i] &= y_i, \\f[x_i, x_{i+1}] &= \frac{f[x_{i+1}] - f[x_i]}{x_{i+1} - x_i}, \\f[x_i, \dots, x_{i+k}] &= \frac{f[x_{i+1}, \dots, x_{i+k}] - f[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i}.\end{aligned}$$

O polinômio de Newton é

$$P_n(x) = f[x_0] + f[x_0, x_1](x - x_0) + \dots + f[x_0, \dots, x_n] \prod_{j=0}^{n-1} (x - x_j).$$

9.3 Exemplo resolvido

Vamos usar os mesmos pontos $(1, 2)$, $(2, 3)$ e $(4, 1)$.

Exemplo resolvido**Passo 1: diferenças de primeira ordem.**

$$f[1, 2] = \frac{3-2}{2-1} = 1, \quad f[2, 4] = \frac{1-3}{4-2} = -1.$$

Passo 2: diferença de segunda ordem.

$$f[1, 2, 4] = \frac{-1-1}{4-1} = -\frac{2}{3}.$$

Passo 3: montar o polinômio.

$$P_2(x) = f[1] + f[1, 2](x-1) + f[1, 2, 4](x-1)(x-2).$$

Logo,

$$P_2(x) = 2 + (x-1) - \frac{2}{3}(x-1)(x-2).$$

Passo 4: simplificar. Expandindo, obtemos novamente o polinômio interpolador do exemplo anterior.**9.4 Tabela triangular de diferenças divididas**

x_i	$f[x_i]$	1ª ordem	2ª ordem
1	2	1	$-2/3$
2	3	-1	
4	1		

10 Interpolação por splines**10.1 Motivação**

Polinômios globais de grau alto podem oscilar muito. Uma solução mais estável é usar **polinômios por partes**. Cada trecho cuida apenas de um subintervalo, e impomos condições de continuidade entre os trechos.

Definição

Uma **spline** é uma função definida por partes em subintervalos $[x_i, x_{i+1}]$, tal que em cada trecho ela é um polinômio e, nos nós, certas derivadas coincidem para garantir suavidade.

10.2 Splines lineares, quadráticas e cúbicas

- **Spline linear:** conecta os pontos com segmentos de reta; é contínua, mas a derivada tem saltos.

- **Spline quadrática:** melhora a suavidade, mas ainda exige tratamento especial de condições de contorno.
- **Spline cúbica natural:** é a mais usada; garante continuidade da função, da primeira e da segunda derivadas, além de impor $S''(x_0) = S''(x_n) = 0$.

10.3 Forma da spline cúbica natural


Em cada intervalo $[x_i, x_{i+1}]$, escrevemos

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3.$$

Os coeficientes são escolhidos para satisfazer:

1. interpolação nos extremos de cada intervalo;
2. continuidade de S nos nós internos;
3. continuidade de S' nos nós internos;
4. continuidade de S'' nos nós internos;
5. condições naturais $S''(x_0) = 0$ e $S''(x_n) = 0$.

10.4 Esquema conceitual



Observação

A grande vantagem das splines é combinar **fidelidade local** com **suavidade global**. Se um ponto mudar, apenas trechos vizinhos são fortemente afetados, ao contrário de um polinômio global de alto grau.

11 Implementação detalhada em Python

Nesta seção, o objetivo é mostrar **como implementar os métodos manualmente**, mas agora em formato de roteiro operacional. Em vez de código pronto, você verá **fluxogramas** e **passos**

de implementação, para que consiga programar cada método em Python por conta própria, entendendo a lógica antes da sintaxe.

Observação


A ideia é sempre a mesma: antes de escrever qualquer linha de Python, organize o método em três níveis:

1. **entradas**: o que o algoritmo recebe;
2. **processamento**: quais cálculos precisam ser feitos;
3. **saídas**: o que deve ser retornado ou exibido.

11.1 Resolvendo sistemas lineares: eliminação de Gauss

Vários métodos desta apostila levam a sistemas lineares. Por isso, o primeiro bloco de implementação deve ser um resolvidor para sistemas da forma

$$A\mathbf{x} = \mathbf{b}.$$

**Passo a passo para implementar:**

1. crie uma função que receba a matriz dos coeficientes e o vetor do lado direito;
2. faça cópias desses dados para evitar modificar a entrada original;
3. percorra as colunas da esquerda para a direita, tratando cada uma como coluna pivô;
4. em cada coluna, verifique se o pivô é diferente de zero; se for muito pequeno, trate o caso como erro numérico ou troque linhas;
5. para cada linha abaixo do pivô, calcule o fator multiplicativo que zera o elemento da coluna atual;
6. subtraia da linha corrente um múltiplo da linha pivô, tanto na matriz quanto no vetor do lado direito;
7. após triangularizar a matriz, resolva o sistema de baixo para cima por substituição retroativa;
8. devolva o vetor solução.

Observação


Se quiser tornar sua implementação mais robusta, o primeiro refinamento a adicionar é o **pivotamento parcial**, isto é, trocar a linha atual pela linha com maior valor absoluto na coluna pivô.

11.2 Implementando regressão linear por MMQ

Na regressão linear, o objetivo é encontrar os coeficientes a_0 e a_1 da reta

$$\hat{y} = a_0 + a_1x.$$

A implementação se resume a calcular somatórios, montar um sistema 2×2 e resolvê-lo.

**Passo a passo para implementar:**

1. receba duas listas do mesmo tamanho: uma para as abscissas e outra para as ordenadas;
2. conte o número de pontos e calcule os quatro somatórios básicos do método;
3. monte a matriz

$$\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix}$$

e o vetor


$$\begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix};$$

4. resolva esse sistema usando a rotina de eliminação de Gauss;

5. armazene os valores encontrados como intercepto e inclinação da reta;
6. crie, se desejar, uma rotina adicional para avaliar a reta em qualquer valor de x .

11.3 Cálculo de resíduos, r^2 e erro padrão

Depois de ajustar a reta, a próxima etapa é medir a qualidade do modelo.



Passo a passo para implementar:


1. usando os coeficientes da reta, calcule o valor previsto em cada ponto experimental;
2. subtraia o valor previsto do valor observado para obter cada resíduo;
3. some os quadrados desses resíduos para obter S_r ;
4. calcule a média dos valores observados y_i ;
5. some os quadrados das diferenças entre cada y_i e a média para obter S_t ;
6. use as fórmulas

$$r^2 = 1 - \frac{S_r}{S_t} \quad \text{e} \quad S_{y/x} = \sqrt{\frac{S_r}{n-2}};$$

7. se quiser o coeficiente de correlação r , tome a raiz de r^2 e use o sinal da inclinação da reta.

11.4 Ajuste polinomial de grau arbitrário

Aqui a lógica é parecida com a regressão linear, mas agora o sistema cresce com o grau do polinômio.



Passo a passo para implementar:


1. escolha o grau m do polinômio que deseja ajustar;
2. calcule todas as somas de potências necessárias: $\sum x_i^0, \sum x_i^1, \dots, \sum x_i^{2m}$;
3. calcule também os termos mistos $\sum x_i^j y_i$ para $j = 0, 1, \dots, m$;
4. monte a matriz de ordem $m + 1$, em que a entrada da linha j e coluna k é $\sum x_i^{j+k}$;
5. monte o vetor do lado direito com os valores $\sum x_i^j y_i$;
6. resolva o sistema linear correspondente;
7. guarde os coeficientes na ordem crescente das potências;
8. para avaliar o polinômio em um ponto, some os termos $a_0 + a_1x + a_2x^2 + \dots + a_mx^m$.

Observação

Na prática, aumentar demais o grau pode piorar o comportamento do ajuste. Implementar é importante, mas escolher bem o grau também é parte essencial do método.

11.5 Interpolação de Lagrange

Nesse método, a implementação consiste em calcular cada bloco fundamental $L_k(x)$ e somá-los ponderados por y_k .



Passo a passo para implementar:

1. receba a lista de nós, a lista de valores correspondentes e o ponto onde deseja interpolar;
2. inicie uma variável acumuladora para a soma final;
3. para cada índice k , inicie um termo com o valor y_k ;
4. percorra todos os demais índices j ;
5. sempre que $j \neq k$, multiplique o termo pelo fator

$$\frac{x - x_j}{x_k - x_j},$$


6. ao terminar os fatores daquele k , adicione o resultado ao acumulador principal;
7. ao final do processo, o acumulador conterá o valor interpolado.

Observação

Ao programar, tenha muito cuidado para não incluir o caso $j = k$ no denominador, pois isso causaria divisão por zero.

11.6 Diferenças divididas de Newton


O método de Newton é mais organizado computacionalmente porque separa a construção dos coeficientes da avaliação do polinômio.

**Passo a passo para implementar:**

1. comece armazenando os valores y_i como a primeira coluna da tabela;
2. construa a segunda coluna usando as diferenças divididas de primeira ordem;
3. continue construindo novas colunas até chegar à ordem máxima desejada;
4. extraia da tabela os coeficientes do polinômio: eles são os primeiros elementos de cada coluna;
5. para avaliar o polinômio em um ponto, comece com o primeiro coeficiente;
6. em seguida, vá acrescentando cada novo coeficiente multiplicado pelo produto acumulado dos fatores $(x - x_0)$, $(x - x_1)$ e assim por diante;
7. retorne o valor final obtido.

11.7 Spline cúbica natural

A spline cúbica natural exige mais organização, mas a lógica pode ser dividida em blocos claros: calcular os espaçamentos, montar o sistema tridiagonal, resolver as derivadas segundas e finalmente montar os polinômios de cada intervalo.

**Passo a passo para implementar:**

1. ordene os nós e calcule os comprimentos de cada subintervalo;
2. monte uma matriz tridiagonal associada às condições de continuidade da spline;
3. construa o vetor do lado direito usando as variações das inclinações entre intervalos consecutivos;
4. imponha as condições naturais, isto é, derivada segunda nula no primeiro e no último nó;
5. resolva o sistema para encontrar as derivadas segundas em todos os nós;
6. em cada intervalo, use essas derivadas segundas para montar os coeficientes do polinômio cúbico local;
7. para avaliar a spline em um ponto qualquer, primeiro descubra em qual intervalo esse ponto está;
8. use apenas os coeficientes daquele intervalo para calcular o valor interpolado.

Observação

A implementação da spline cúbica natural parece longa, mas conceitualmente ela se divide em duas tarefas simples: **garantir suavidade global** e **avaliar um polinômio local em cada intervalo**.

12 Quando usar cada método?

Método	Quando usar	Comentário principal
Regressão linear	Tendência aproximadamente reta	Simples, interpretável e eficiente
Linearização + MMQ	Modelo não linear com transformação conveniente	Exige cuidado ao interpretar os erros na variável original
Ajuste polinomial MMQ	Tendência curva com ruído	Grau alto pode causar instabilidade e sobreajuste
Lagrange	Poucos pontos e necessidade de fórmula explícita	Pouco prático para acrescentar novos nós
Newton	Interpolação com possível adição de novos pontos	Mais eficiente que Lagrange para atualização incremental
Spline cúbica	Muitos pontos e necessidade de suavidade	Excelente equilíbrio entre estabilidade e fidelidade local

13 Conclusão

O conteúdo do PDF mostra uma linha de raciocínio muito importante em análise numérica: começamos com a necessidade de representar dados, depois escolhemos entre interpolar ou aproximar, em seguida medimos a qualidade do modelo e, por fim, adotamos técnicas mais flexíveis quando a complexidade do problema aumenta.

Nesta apostila, vimos que:

- o MMQ produz ajustes que minimizam a soma dos quadrados dos resíduos;
- a regressão linear é apenas o caso mais simples de uma ideia mais geral;
- modelos não lineares podem, em vários casos, ser linearizados;
- a interpolação polinomial fornece exatidão nos nós, mas nem sempre estabilidade global;
- splines são ferramentas poderosas para obter curvas suaves com bom comportamento numérico.

Observação

Se você estiver estudando para disciplina ou prova, uma boa estratégia é praticar nesta ordem:

1. regressão linear e interpretação dos resíduos;
2. linearização de modelos;
3. ajuste polinomial por MMQ;
4. Lagrange e Newton;
5. spline cúbica natural.

Essa sequência respeita a progressão do mais simples para o mais sofisticado.